

# 朴素贝叶斯法的学习和分类

2024年4月23日 15:13

朴素贝叶斯假设：

假设特征 $x = (x_1, x_2, x_3, x_4, \dots, x_n)$ ，相对于标签值 $y$ 条件独立

对于特征 $X = (x_1, x_2, \dots, x_n)$ ，满足  $x_i \perp x_j | y (i \neq j)$

$$p(X|y) = p(x_1, x_2, \dots, x_n|y) = \prod_{j=1}^n p(x_j|y)$$

朴素贝叶斯法：

根据贝叶斯法则，先验概率算后验概率。

$$p(y|x) = \frac{p(x, y)}{p(x)} = \frac{p(x|y)p(y)}{p(x)} = \frac{p(x|y)p(y)}{\sum_i p(x|y_i)p(y_i)} \propto p(x|y)p(y)$$

目标是：根据最大似然法，让得出来的最后分法是所有分法中概率最大的那个

$$\begin{aligned} y &= \arg \max_y p(y|X) = \arg \max_y \frac{p(X, y)}{p(X)} = \arg \max_y p(X|y)p(y) \\ &= \arg \max_y \prod_i p(x_i|y) p(y) \end{aligned}$$

例子：

例 4.1 试由表 4.1 的训练数据学习一个朴素贝叶斯分类器并确定  $x = (2, S)^T$  的类标记  $y$ 。表中  $X^{(1)}$ 、 $X^{(2)}$  为特征，取值的集合分别为  $A_1 = \{1, 2, 3\}$ ， $A_2 = \{S, M, L\}$ ， $Y$  为类标记， $Y \in C = \{1, -1\}$ 。

表 4.1 训练数据															
	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
$X^{(1)}$	1	1	1	1	1	2	2	2	2	2	3	3	3	3	3
$X^{(2)}$	S	M	M	S	S	S	M	M	L	L	L	M	M	L	L
$Y$	-1	-1	1	1	-1	-1	-1	1	1	1	1	1	1	1	-1

	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
$X^{(1)}$	1	1	1	1	1	2	2	2	2	2	3	3	3	3	3
$X^{(2)}$	S	M	M	S	S	S	M	M	L	L	L	M	M	L	L
$Y$	-1	-1	1	1	-1	-1	-1	1	1	1	1	1	1	1	-1

$$\begin{aligned} P(Y=1) &= \frac{9}{15}, \quad P(Y=-1) = \frac{6}{15} \\ P(X^{(1)}=1|Y=1) &= \frac{2}{9}, \quad P(X^{(1)}=2|Y=1) = \frac{3}{9}, \quad P(X^{(1)}=3|Y=1) = \frac{4}{9} \\ P(X^{(2)}=S|Y=1) &= \frac{1}{9}, \quad P(X^{(2)}=M|Y=1) = \frac{4}{9}, \quad P(X^{(2)}=L|Y=1) = \frac{4}{9} \\ P(X^{(1)}=1|Y=-1) &= \frac{3}{6}, \quad P(X^{(1)}=2|Y=-1) = \frac{2}{6}, \quad P(X^{(1)}=3|Y=-1) = \frac{1}{6} \\ P(X^{(2)}=S|Y=-1) &= \frac{3}{6}, \quad P(X^{(2)}=M|Y=-1) = \frac{2}{6}, \quad P(X^{(2)}=L|Y=-1) = \frac{1}{6} \end{aligned}$$

对于给定的  $x = (2, S)^T$  计算：

$$\begin{aligned} P(Y=1)P(X^{(1)}=2|Y=1)P(X^{(2)}=S|Y=1) &= \frac{9}{15} \cdot \frac{3}{9} \cdot \frac{1}{9} = \frac{1}{45} \\ P(Y=-1)P(X^{(1)}=2|Y=-1)P(X^{(2)}=S|Y=-1) &= \frac{6}{15} \cdot \frac{2}{6} \cdot \frac{3}{6} = \frac{1}{15} \end{aligned}$$

因为  $P(Y=-1)P(X^{(1)}=2|Y=-1)P(X^{(2)}=S|Y=-1)$  最大，所以  $y = -1$ 。 ■

贝叶斯估计：

测试样例的特征没有在训练集中出现，即训练集的数据不完整，有特征值缺失，比

如头发特征有黑头发，白头发，红头发。但是训练集里面只有黑头发和白头发，会影响后验概率

解决：加个调节因子 $\lambda$  ( $\lambda$ )  $x_k$ 特征有多少种取值和  $\lambda$  (取值1，拉普拉斯平滑)

**思考：**在前面的分类算法中，如果测试样例中的特征没有出现在训练集中出现会造成什么结果？

会影响到后验概率的计算结果，使分类产生偏差。解决这一问题的方法是采用**贝叶斯估计**。具体地，估计特征 $x_k$ 的条件概率为：

$$p(x_k|y_i) = \frac{C(x_k, y_i) + \lambda}{C(y_i) + K(x_k)\lambda}$$

估计 $y_i$ 的概率计算为：

$$p(y_i) = \frac{C(y_i) + \lambda}{N + K(y_i)\lambda}$$

式中 $C$ 表示符合条件的样本个数,  $K(x)$ 为特征 $x$ 的取值种类数,  $\lambda \geq 0$ 。等价于在随机变量各个取值的频数上赋予一个正数 $\lambda \geq 0$ 。当 $\lambda = 0$ 时就是极大似然估计。一般取 $\lambda = 1$ ，这时称为**拉普拉斯平滑** (Laplacian smoothing)。

例子：

	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
$X^{(1)}$	1	1	1	1	1	2	2	2	2	2	3	3	3	3	3
$X^{(2)}$	S	M	M	S	S	S	M	M	L	L	L	M	M	L	L
$Y$	-1	-1	1	1	-1	-1	-1	1	1	1	1	1	1	1	-1

$$P(Y = 1) = \frac{10}{17}, \quad P(Y = -1) = \frac{7}{17}$$

$$P(X^{(1)} = 1|Y = 1) = \frac{3}{12}, \quad P(X^{(1)} = 2|Y = 1) = \frac{4}{12}, \quad P(X^{(1)} = 3|Y = 1) = \frac{5}{12}$$

$$P(X^{(2)} = S|Y = 1) = \frac{2}{12}, \quad P(X^{(2)} = M|Y = 1) = \frac{5}{12}, \quad P(X^{(2)} = L|Y = 1) = \frac{5}{12}$$

$$P(X^{(1)} = 1|Y = -1) = \frac{4}{9}, \quad P(X^{(1)} = 2|Y = -1) = \frac{3}{9}, \quad P(X^{(1)} = 3|Y = -1) = \frac{2}{9}$$

$$P(X^{(2)} = S|Y = -1) = \frac{4}{9}, \quad P(X^{(2)} = M|Y = -1) = \frac{3}{9}, \quad P(X^{(2)} = L|Y = -1) = \frac{2}{9}$$

$$P(Y = 1)P(X^{(1)} = 2|Y = 1)P(X^{(2)} = S|Y = 1) = \frac{10}{17} \cdot \frac{4}{12} \cdot \frac{2}{12} = \frac{5}{153} = 0.0327$$

$$P(Y = -1)P(X^{(1)} = 2|Y = -1)P(X^{(2)} = S|Y = -1) = \frac{7}{17} \cdot \frac{3}{9} \cdot \frac{4}{9} = \frac{28}{459} = 0.0610$$

由于 $P(Y = -1)P(X^{(1)} = 2|Y = -1)P(X^{(2)} = S|Y = -1)$ 最大，所以 $y = -1$ 。 ■

**KNN算法：**

想法：取离 $q$ 最近的 $k$ 个样本的标签众数为 $q$ 的标签

例子：

• **K-近邻(KNN)算法—KNN处理分类问题:步骤**

Document number	1	buy	an	apple	...	friend	has	emotion
train 1	1	1	1	1	...	0	0	happy
train 2	1	0	0	1	...	0	0	happy
train 3	0	0	0	1	...	0	0	sadness
test 1	0	0	1	1	...	1	1	?

2. 相似度计算：计算test1与每个train的距离

欧氏距离：

$$d(\text{train1}, \text{test1}) = \sqrt{(1-0)^2 + (1-0)^2 + \dots + (0-1)^2} = \sqrt{6};$$

$$d(\text{train2}, \text{test1}) = \sqrt{(1-0)^2 + (1-0)^2 + \dots + (0-1)^2} = \sqrt{8};$$

$$d(\text{train3}, \text{test1}) = \sqrt{(0-0)^2 + (0-0)^2 + \dots + (0-1)^2} = \sqrt{9};$$

(也可以使用其他距离度量方式)

3. 类别计算：最相似的 $k$ 个样本之标签的众数

若 $k=1$ ，test1的标签即为train1的标签happy；

若 $k=3$ ，test1的标签为train1,train2,train3的标签中数量较多的，即为happy。

参数设置：

通过验证集对参数 $k$ 进行调优：

- 通过验证集对参数(k值)进行调优
  - 如果k值取的过大, 学习的参考样本更多, 会引入更多的噪音, 所以可能存在欠拟合的情况;
  - 如果k值取的过小, 参考样本少, 容易出现过拟合的情况
  - 关于k的经验公式: 一般取 $k = \sqrt{N}$ , N为训练集实例个数, 大家可以尝试一下

权重归一化:

### 权重归一化

Name	Formula	Explain
Standard score	$X' = \frac{X - \mu}{\sigma}$	$\mu$ is the mean and $\sigma$ is the standard deviation
Feature scaling	$X' = \frac{X - X_{min}}{X_{max} - X_{min}}$	$X_{min}$ is the min value and $X_{max}$ is the max value

不同权重的距离度量公式:

曼哈顿距离和欧式距离:

距离公式:

$L_p$  距离 (所有距离的总公式):

$$L_p(x_i, x_j) = \left\{ \sum_{l=1}^n |x_i^{(l)} - x_j^{(l)}|^p \right\}^{\frac{1}{p}}$$

$p = 1$ : 曼哈顿距离;  
 $p = 2$ : 欧氏距离, 最常见。

例 3.1 已知二维空间的 3 个点  $x_1 = (1, 1)^T$ ,  $x_2 = (5, 1)^T$ ,  $x_3 = (4, 4)^T$ , 试求在  $p$  取不同值时,  $L_p$  距离下  $x_1$  的最近邻点。  
 解 因为  $x_1$  和  $x_2$  只有第一维的值不同, 所以  $p$  为任何值时,  $L_p(x_1, x_2) = 4$ , 而  
 $L_1(x_1, x_3) = 6$ ,  $L_2(x_1, x_3) = 4.24$ ,  $L_3(x_1, x_3) = 3.78$ ,  $L_4(x_1, x_3) = 3.57$   
 于是得到:  $p$  等于 1 或 2 时,  $x_2$  是  $x_1$  的最近邻点;  $p$  大于等于 3 时,  $x_3$  是  $x_1$  的最近邻点。

余弦相似度:

余弦相似度:

余弦相似度:

$$\cos(\vec{A}, \vec{B}) = \frac{\vec{A} \cdot \vec{B}}{|\vec{A}| |\vec{B}|}, \text{ 其中 } \vec{A} \text{ 和 } \vec{B} \text{ 表示两个文本特征向量;}$$

余弦值作为衡量两个个体间差异的大小的度量

为正且值越大, 表示两个文本差距越小, 为负代表差距越大, 请大家自行脑补两个向量余弦值

## 6.1 K-近邻(KNN)算法—KNN算法效率

假设训练集有N个样本, 测试集有M个样本, 每个样本是一个V维的向量。

如果使用线性搜索的话, 那么k-NN的时间花销就是 $O(N * M * V)$ 。

改善: KD树(感兴趣可自行尝试)

```
#将所有数据的后验概率算出, 分两个list【dict】 第一个list是y为2是特征值的情况, dict
的key为特征值, count为计数, sum局部y计数, y也是找个sum计数
#还要算Y的概率
#乘起来, 找概率最大的
```

